

Makine Öğrenmesi Yöntemleri ile SMS Mesajlarındaki İstenmeyen Mesajların (Spam) Tespiti

Kübra Topcu, Bilgisayar Mühendisliği Bölümü, Teknoloji Fakültesi, Gazi Üniversitesi,
Ankara, Türkiye, 24181616024@gazi.edu.tr

Zeynep Baykan, Bilgisayar Mühendisliği Bölümü, Teknoloji Fakültesi, Gazi Üniversitesi,
Ankara, Türkiye, 24181616026@gazi.edu.tr

Github Linki: https://github.com/zeynepbykn/SMS_Spam_Tespiti_Proje

ÖZET

Bu çalışma, mobil iletişim ağlarında kullanıcı güvenliğini tehdit eden spam (istenmeyen) mesajların tespit edilmesini amaçlamaktadır. Bu kapsamda 5.572 mesaj içeren “SMS Spam Collection” veri seti kullanılarak kapsamlı bir sınıflandırma analizi gerçekleştirilmiştir.

Metin verileri Doğal Dil İşleme (NLP) teknikleri ile ön işleme aşamasından geçirilmiş; gürültülerin temizlenmesi ve durak kelimelerin çıkarılması işlemleri uygulanmıştır. Ardından metinler modellerin veriyi işleyebilmesi amacıyla TF-IDF yöntemi ile sayısal vektörlere dönüştürülmüştür.

Çalışmada 9 farklı makine öğrenmesi algoritmaları kullanılarak karşılaştırmalı bir analiz yapılmıştır. Elde edilen sonuçlara göre LSTM modeli %98,9 doğruluk ve %96,0 F1-skoru ile en başarılı performansı göstermiştir. Sonuçlar, önerilen yaklaşımın spam tespitinde yüksek doğrulukla çalıştığını ve mobil güvenlik sistemleri için etkili bir çözüm sunduğunu göstermektedir.

Anahtar Kelimeler: SMS Spam Sınıflandırma, Makine Öğrenmesi, Metin Madenciliği, Karşılaştırmalı Performans Analizi, Siber Güvenlik.

1. GİRİŞ

Günümüzde mobil cihaz kullanımının artmasıyla birlikte SMS hizmetleri, bireysel haberleşmenin yanı sıra bankacılık, doğrulama sistemleri ve pazarlama faaliyetlerinde de yaygın olarak kullanılmaya başlanmıştır. Ancak bu durum, “spam” olarak adlandırılan istenmeyen mesajların artışını da beraberinde getirmiştir. Bu tür mesajlar kullanıcılar için yalnızca rahatsız edici olmakla kalmayıp, aynı zamanda oltalama (phishing) gibi siber saldırılar için de risk oluşturmaktadır.

Artan mesaj trafiği içerisinde spam içeriklerin manuel olarak ayırt edilmesi günümüzde oldukça zor hale gelmiştir. Bu nedenle mobil ağ operatörleri ve son kullanıcılar için otomatik, hızlı ve güvenilir tespit sistemlerine ihtiyaç duyulmaktadır.

Bu çalışmada, istenmeyen mesajların doğru şekilde sınıflandırılmasını sağlayabilecek bir model geliştirilmesi amaçlanmıştır. Bu kapsamda ham metin verileri Doğal Dil İşleme (NLP) yöntemleri ile ön işleme aşamasından geçirilmiş ve veri setinin yapısına uygun

olarak TF-IDF yöntemi ile sayısal özniteliklere dönüştürülmüştür. Çalışmanın temel odağı, farklı makine öğrenmesi algoritmalarının sınıflandırma performanslarını karşılaştırmalı olarak incelemek ve veri setindeki sınıf dengesizliğinin (imbalance) model başarısı üzerindeki etkisini değerlendirmektir.

Çalışma kapsamında gerçekleştirilen analizlerde şu temel araştırma sorularına yanıt aranmıştır:

- Soru 1: Uygulanan NLP ön işleme ve TF-IDF ağırlıklandırma adımları; 'free', 'win', 'call' gibi spam mesajlara özgü anahtar kelimelerin ayırt ediciliğini ve öznitelik kalitesini ne ölçüde artırmaktadır?
- Soru 2: Karar sınırlarını geometrik bir düzlemde optimize ederek kelimeleri ayırtıran geleneksel makine öğrenmesi yöntemi (SVM) ile, kelimelerin cümlede neresinde geçtiğini ve bağlamını hafızasında tutabilen derin öğrenme mimarisi (LSTM) arasında, karmaşık SMS metinlerini çözmede performans açısından bir fark var mıdır?"
- Soru 3: Veri setindeki sınıfsal dengesizliğin (ham mesajların spam mesajlara göre sayıca üstünlüğü), modellerin özellikle spam sınıfı üzerindeki duyarlılık (recall) başarısı üzerinde nasıl bir etkisi vardır?

Bu makalede; Naive Bayes, Lojistik Regresyon, SVM, Karar Ağaçları, Random Forest, Yapay Sinir Ağları, XGBoost, LSTM ve KNN olmak üzere toplam dokuz farklı algoritmanın başarı metrikleri üzerinden karşılaştırmalı analizi sunulmaktadır. Elde edilen bulgular, mobil güvenlik sistemleri için hangi algoritmik yaklaşımların daha güvenilir olduğunu teknik verilerle ortaya koymaktadır.

2. MATERYAL VE YÖNTEM

Bu bölümde, SMS spam sınıflandırma sistemimizi geliştirirken kullandığımız veri kaynağı, metinleri analiz edilebilir hale getirdiğimiz ön işleme adımları ve performanslarını ölçtüğümüz algoritmalar detaylandırılmıştır.


2.1. Veri Seti

Çalışmamızda kullanılan "SMS Spam Collection" veri seti, toplamda 5.574 adet İngilizce kısa mesajdan oluşmaktadır. Bu veri seti; Grumbletext web sitesinden manuel olarak toplanan spam mesajlar, Caroline Tag'in doktora tezinden alınan meşru mesajlar ve NUS SMS Külliyyatı (NSC) gibi farklı güvenilir kaynakların bir araya getirilmesiyle oluşturulmuştur.

Veri setimizin karakteristik yapısını ve dağılımını şu şekilde özetleyebiliriz:

- Toplam Mesaj Sayısı: 5.572 adet.
- Ham (Normal) Mesajlar: 4.825 adet (%86,6).

- Spam (İstenmeyen) Mesajlar: 747 adet (%13,4).
- Veri Yapısı: Veri setimiz etiket (label) ve ham metin (message) olmak üzere iki ana sütundan oluşmaktadır.



Ham mesajların sayısının spam mesajların yaklaşık 6,5 katı olduğu gözlemlenmektedir. Bu “sınıfsal dengesizlik”, model eğitimi sırasında spam sınıfına özgü ayırt edici özelliklerin öğrenilmesini zorlaştırabilecek bir faktördür. Bu nedenle, model başarısının değerlendirilmesinde sadece doğruluk (accuracy) oranı ile yetinilmemiş; kesinlik (precision), duyarlılık (recall) ve F1-skoru gibi metrikler de analiz edilmiştir.

Gerçekleştirilen içerik analizi sonucunda; ham mesajların genellikle günlük sohbet dilini yansıtan ifadeler içerdiği, spam mesajların ise “free” (ücretsiz), “win” (kazandınız) veya “claim” (talep et) gibi kullanıcıyı aksiyona zorlayan finansal ödül ve baskı unsuru taşıyan anahtar kelimeler barındırdığı gözlemlenmiştir.

2.2. Kullanılan Makine Öğrenmesi Algoritmaları

Ham veri setindeki metinler, makine öğrenmesi modellerine doğrudan girdi olarak verilemeyecek kadar karmaşık bir yapıdadır. Bu nedenle, algoritmaların mesajlardaki anlamsal örüntüleri daha iyi yakalayabilmesi için bir ön işleme süreci yürütülmüştür.

2.2.1. Veri Temizleme (NLP Preprocessing)

Kodlama aşamasında, her bir mesaj üzerinde adım adım şu temizleme işlemlerini gerçekleştirdik:

- **Küçük Harf Dönüşümü:** Analiz sırasında "Free" ve "free" kelimelerinin farklı özellikler olarak algılanmaması için tüm metni küçük harfe çevirerek standartlaştırılmıştır.
- **Noktalama ve Sayı Temizliği:** Mesajlardaki ünlem, soru işareti gibi noktalama işaretlerini ve sayısal değerleri, mesajın ham ve spam olarak ayrılmasında bir etkisi olmadığı için ve veri setine gürültü kattığı için string.punctuation kütüphanesini kullanarak temizledik.

- **Stopwords (Durak Kelimeler) Temizliği:** İngilizce dilinde çok sık geçen ancak metnin sınıfını belirlemede yer almayan, ayırt edici olmayan (the, is, in vb.) kelimeleri nltk.corpus kütüphanesinden yararlanarak veri setinden arındırdık.
- **Tokenlaştırma (Tokenization):** Temizlenen metinler, kelimelere (token) dönüştürülmüştür. Böylece metinler makine öğrenmesi modelleri için işlenebilir bir yapıya kavuşturulmuştur.

2.2.2. TF-IDF ile Vektörleştirme

Metinleri temizleme işlemi bittikten sonra metinleri modelin işleyebilmesi için matematiksel bir forma (sayısal vektörlere) dönüştürmemiz gereklidir. Bunun için, basit kelime sayma yönteminden daha gelişmiş olan TF-IDF (Term Frequency-Inverse Document Frequency) yöntemi kullanılmıştır. Bu yöntemi seçmemizin temel sebebi, bir kelimenin hem ilgili mesajdaki sıklığını hem de tüm veri setindeki "nadirlik" derecesini hesaplamasıdır. Ayrıyeten hesaplamalar sırasında modelin karmaşıklığını kontrol altında tutmak ve gürültülü verileri engellemek amacıyla, en yüksek skora sahip 3.000 özellik (kelime) ile sınırlandırma yaparak boyut azaltma işlemi uygulanmıştır. Böylece spam mesajlarda çok sık geçen (örneğin: 'free', 'claim') ancak ham mesajlarda nadir bulunan kelimelerin ağırlığını artırarak modellerin daha keskin kararlar vermesi sağlanmıştır.

2.2.3. Sınıflandırma Modelleri ve Karşılaştırma

SMS metinlerinin sınıflandırılmasında en etkili yaklaşımı belirlemek amacıyla, literatürde metin madenciliği için yaygın olarak kullanılan hem istatistiksel hem de derin öğrenme temelli toplam 9 farklı algoritma uygulanmıştır. Kullanılan algoritmalar ve temel özellikleri aşağıda sunulmuştur:

- **Naive Bayes (MultinomialNB):** Olasılıksal bir sınıflandırıcı olan bu algoritma, her bir kelimenin sınıfa olan katkısını bağımsız birer olasılık olarak hesaplar. Çalışmamızda kullandığımız 3.000 farklı öznelik (boyut) gibi çok sayıda değişken içeren verilerde, hesaplama hızı ve verimliliği nedeniyle metin sınıflandırma işlemlerinde referans model olarak kabul edilir.
- **Lojistik Regresyon:** Lojistik regresyon, metinlerin belirli bir sınıfa ait olma olasılığını hesaplayan doğrusal bir modeldir. Model her kelimeye bir ağırlık verir, mesaj içerisindeki kelimelerin TF-IDF değerleri bu katsayılar ile çarpılarak ve matematiksel işlemlere sokarak bir olasılık verir. Son aşamada, belirlenen 0.5 karar eşiği kullanılarak mesajlar (ham/spam) sınıflandırılır.
- **Destek Vektör Makineleri (SVM):** SVM, yüksek boyutlu veri uzaylarında güçlü performans gösteren bir algoritmadır. Kelimeleri temsil eden TF-IDF vektörlerini n-boyutlu bir uzayda noktalar olarak konumlandırır. SVM, "Ham" ve "Spam" sınıflarını birbirinden ayırmak için maksimum marjın ile en uygun ayırım sınırını belirler ve

gelen yeni mesaja karşı objektif davranmasını sağlar. Diğer modellere göre daha yüksek performans sergilediği gözlemlenmiştir. Eğitim sürecinde doğrusal (linear) kernel kullanılmış ve C (C= 1.0) parametresi optimize edilerek modelin hem eğitim setindeki başarısı hem de test setindeki genelleme kapasitesi dengelenmiştir.

- **K-En Yakın Komşu (KNN):** KNN algoritması, yeni bir veriyi en yakın komşularına göre sınıflandıran mesafe tabanlı bir yöntemdir. Sistem yeni gelen mesajı diğer mesajlarla olan mesafesini hesaplar ve belirlenen optimum k (k=5) değerine göre sınıflandırma yapılır.
- **Karar Ağaçları (Decision Tree):** Karar ağaçları, veriyi belirli kurallara göre bölerek sınıflandırma yapan sezgisel modellerdir. Bu çalışmada, metinlerdeki kelime ağırlıklarını (TF-IDF) kullanarak "Evet/Hayır" mantığıyla çalışan karar kuralları oluşturulmuştur. Algoritma, her aşamada en yüksek bilgi kazancını (ham ve spam mesajları en keskin şekilde ayırabilen) sağlayan öznelilikleri belirlemek için Gini Safsızlığı(karmaşıklık düşüren) kullanır. Ancak, modelin eğitim verisini ezberlemesine (overfitting) karşı, kodlama aşamasında maksimum derinlik sınırlandırılmıştır.
- **Rastgele Orman (Random Forest):** Birden fazla karar ağacının bir araya gelmesiyle oluşan bir toplu öğrenme yöntemidir. Algoritma, belirlenen 100 adet bağımsız ağacın her birini kelimelerin rastgele bir alt kümesi üzerinde eğiterek, modellerin belirli baskın değişkenlere (call, free vb.) veya veri setindeki gürültülere aşırı odaklanmasını engeller. Sınıflandırma sürecinde bu ağaçların ürettiği tahminler arasından en çok oy alan sınıf sonuç olarak belirlenir. Bu yapı sayesinde tekil ağaçlara göre daha dengeli ve genellenebilir sonuçlar elde edilmiştir.
- **XGBoost:** XGBoost algoritması, hataları iteratif olarak azaltmaya çalışan güçlü bir gradyan artırma yöntemidir. Rastgele Orman modelinden farklı olarak ağaçları ardışık inşa eder; her yeni ağaç, bir önceki ağacın tahmin hatalarını (artıkları) minimize etmek için sisteme eklenir. Modelin her adımda hataları hedefleyerek ilerlemesi, yüksek doğruluk ve hız sağlar. Çalışmada, öğrenme oranı ve ağaç derinliği gibi parametreler optimize edilerek spam tespiti yapılmıştır.
- **Yapay Sinir Ağları (YSA):** Yapay Sinir Ağları, insan beyninin bilgi işleme yöntemini modelleyen, verideki karmaşık ilişkileri öğrenebilen katmanlı ve esnek modellerdir.

TF-IDF ile vektörleştirilen veriler, gizli katmanlardaki nöronlar ve aktivasyon fonksiyonları sayesinde kelimeler arasındaki bağları yakalayarak ilişkileri çözer. Eğitim sürecinde kullanılan "Geriye Yayılım" yöntemiyle model, yaptığı hataları her adımda kontrol ederek hata payını en aza indirmeye çalışır. Bu sayede sistem, 3.000 farklı kelime arasındaki derin ilişkileri keşfederek yüksek doğrulukla spam tespiti yapabilmektedir.

- **LSTM:** LSTM, metin gibi sıralı verileri işlemek için tasarlanmış gelişmiş bir derin öğrenme mimarisidir. Klasik algoritmalar kelimeleri bağımsız olarak değerlendirirken, LSTM kelimelerin diziliş sırasını ve bağlamını hafızasında tutar. Çalışmada, SMS metinleri modele birer kelime dizisi (sequence) olarak verilmiştir. İçerisindeki özel hafıza kapıları sayesinde model, cümleyi okurken hangi bilgilerin hatırlanıp hangilerinin unutulacağına karar verir. Bu güçlü bağlam anlama yeteneği, sistemin karmaşık spam mesajlarını en düşük hata payıyla tespit etmesini sağlamıştır.

Bu bölümde yer alan her algoritma, veri setinin %80'i ile eğitilmiş ve %20'lik test seti üzerinde değerlendirilmiştir. Eğitim sürecinde modellerimiz, eğitim setindeki kelime ağırlıklarına bakarak hangi kavramların spam sınıfına işaret ettiğini kavramıştır. Test aşamasında ise, daha önce hiç görmedikleri test mesajlarını bu kurallar üzerinden sınıflandırarak gerçek dünya performanslarını sergilemişlerdir.

2.3. Literatür Taraması

İstenmeyen e-posta ve SMS (spam) mesajlarının otomatik tespiti, günümüzde önemli bir araştırma alanı haline gelmiştir. İlk çalışmalar daha çok kural tabanlı sistemlere dayanırken, veri miktarının artmasıyla birlikte makine öğrenmesi ve derin öğrenme yöntemleri ön plana çıkmıştır. Spam göndericilerinin zamanla daha karmaşık yöntemler geliştirmesi, bu alandaki tekniklerin de gelişmesini zorunlu kılmıştır.

Kısa metinlerin sınıflandırılmasında, verinin sayısal hale getirilmesi model başarısını doğrudan etkilemektedir. Ekici ve Takcı (2021), Türkçe veri setleri üzerinde yaptıkları çalışmada TF-IDF yönteminin Word2Vec'e kıyasla daha kararlı sonuçlar verdiğini göstermiştir. Benzer şekilde Saputra (2024), TF-IDF temelli özniteliklerin kısa mesajlardaki ayırt edici kelimeleri yakalamada yüksek başarı sağladığını belirtmiştir.

Model performansları açısından farklı algoritmaların öne çıktığı görülmektedir. Akçetin ve Çelik (2015), karar ağacı tabanlı yöntemleri karşılaştırdıkları çalışmada en yüksek başarının Random Forest ile elde edildiğini raporlamıştır. Eşidir (2025) ise SMS verileri üzerinde Lojistik Regresyon modelinin yüksek doğruluk ve AUC değerleri ile başarılı sonuçlar verdiğini ifade etmiştir. Ayrıca Güven (2023), Türkçe e-postalar üzerinde yaptığı çalışmada BERT ve ELECTRA gibi yeni nesil modellerin klasik Yapay Sinir Ağlarına göre daha yüksek performans gösterdiğini ortaya koymuştur.

Veri setinin orijinal sahipleri tarafından yapılan çalışmada, Destek Vektör Makineleri (SVM) modellerinin test edildiği ve %97,8 gibi oldukça yüksek doğruluk oranlarına ulaşıldığı rapor edilmiştir.

Genel olarak literatürde, hem geleneksel makine öğrenmesi yöntemlerinin hem de daha karmaşık modellerin başarılı sonuçlar verdiği görülmektedir. Ancak veri setinin yapısı, özellikle sınıf dengesizliği ve öznitelik boyutu, model performansını doğrudan etkilemektedir.

Bu çalışmada, bu faktörler dikkate alınarak dokuz farklı makine öğrenmesi algoritması aynı ön işleme adımları altında karşılaştırılmış ve en uygun model belirlenmeye çalışılmıştır.


3. BULGULAR VE TARTIŞMA

Bu bölümde, veri setine uygulanan metin ön işleme adımları ve TF-IDF vektörizasyonu sonrasında eğitilen dokuz farklı makine öğrenmesi modelinin performansı ele alınmıştır. Elde edilen bulgular, çeşitli başarı metrikleri ve karmaşıklık matrisleri kullanılarak değerlendirilmiştir. Ayrıca, sonuçlar SMS spam tespiti açısından yorumlanarak modellerin etkinliği üzerinde durulmuştur.

3.1 Bulgular

Bu alt bölümde, eğitilen dokuz farklı modelin test veri seti üzerindeki performansları tablo ve grafikler aracılığıyla sunulmaktadır. Bunun yanı sıra, modellerin genel başarı düzeyleri incelenmiş ve sınıflandırma hatalarının hangi sınıflarda yoğunlaştığı analiz edilerek sonuçlar daha anlaşılır hale getirilmiştir.


3.1.1 Öznitelik Önem Düzeyi Grafiği



Şekil 3.1.1 Öznitelik Önem Düzeyi Grafiği

Karar Ağacı modeline ait öznitelik önem analizi sonuçları Şekil 3.1.1’de gösterilmektedir. Analiz sonuçlarına göre, Karar Ağacı algoritmasının bir mesajın "spam" olup olmadığına karar verirken kullandığı en belirleyici kelimenin “call” kelimesi olduğu görülmektedir. Bu özneliği sırasıyla 'txt', 'free', 'stop' ve 'claim' anahtar kelimeleri takip etmektedir.


3.1.2 ROC Grafiği



ROC eğrisi, sınıflandırma modellerinin farklı karar eşikleri altında gösterdiği performansı değerlendirmek için kullanılan bir ölçüttür. Eğrinin altında kalan alanı temsil eden AUC (Eğri Altı Alan) skoru ise, modelin iki sınıfı (spam ve ham) birbirinden ayırma konusundaki genel ayırt edicilik gücünü sayısal olarak göstermektedir.

Şekil 3.1.2, dokuz modelin spam tespitindeki ROC eğrilerini ve AUC skorlarını karşılaştırmaktadır. Eğrilerin sol üst köşeye yakınlığı yüksek doğruluğu simgelerken; LSTM (0.995), Random Forest (0.994) ve YSA (0.989) modellerinin en yüksek AUC değerlerine sahip olduğu görülmektedir. KNN (0.827) diğerlerine göre daha geride kalmıştır.

3.1.3 En Başarılı ve En Düşük Performanslı Modellerin Karmaşıklık Matrisleri




Şekil 3.1.3 En iyi ve En Başarısız Modellerin Karmaşıklık Matrisleri

Bu çalışmada, en yüksek performans gösteren LSTM modeli ile en düşük performans gösteren KNN modeline ait karmaşıklık matrisleri Şekil 3.1.3'te sunulmuştur. Değerlendirme, toplam 1115 test verisi üzerinden gerçekleştirilmiştir.

- **LSTM Modeli:** 966 adet gerçek "Ham" mesajın 959'unu doğru sınıflandırmış, sadece 7 adet mesajı spam (Yanlış Alarm) olarak etiketlemiştir. 149 adet gerçek "Spam" mesajın ise 144 tanesini başarıyla yakalamış, sadece 5 adet spam mesajı kaçırmıştır.
- **KNN Modeli:** 966 adet "Ham" mesajın tamamını doğru sınıflandırarak 0 Yanlış Alarm oranıyla çalışmıştır. Ancak, 149 "Spam" mesajın 84 tanesini "Ham" olarak yanlış sınıflandırmış (Kaçan Spam) ve sadece 65 mesajı spam olarak doğru tespit edebilmiştir.

Karmaşıklık matrisi sonuçları genel olarak değerlendirildiğinde, LSTM modelinin her iki sınıf için en güvenilir ve dengeli sonuçları verdiği; KNN modelinin ise özellikle spam mesajları tespit etme konusunda çok yetersiz kaldığı görülmektedir.

3.1.4 Modellerin Performans Metrikleri Üzerinden Karşılaştırılması



Şekil 3.1.4 Modellerin Başarı Metrikleri

Bu çalışmada kullanılan dokuz farklı algoritmanın doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1-skoru değerlerine ilişkin karşılaştırmalı sonuçlar Şekil 3.1.4'te sunulmaktadır. Grafik incelendiğinde, modellerin performans düzeyleri ve hata türleri açısından bazı farklılıklar gösterdiği görülmektedir.

- **Genel Performans:** LSTM (%98,9 doğruluk) ve SVM (%98,8 doğruluk) algoritmaları, tüm metriklerde dengeli ve en yüksek değerleri elde ederek çalışmanın en başarılı modelleri olmuştur.

- **Kesinlik (Precision):** Naive Bayes, Random Forest ve KNN modellerinde kesinlik değerinin %100 olduğu görülmektedir. Bu durum, söz konusu modellerin normal (ham) mesajları kesinlikle spam olarak işaretlemediğini (0 Yanlış Alarm) göstermektedir.
- **Duyarlılık (Recall) ve Spam Yakalama Performansı:** KNN (%43,6) ve Karar Ağacı (%63,1) modelleri, diğer algoritmalara kıyasla en düşük duyarlılık değerlerini sergilemiştir. LSTM ise %96,6 duyarlılık oranıyla spam mesajları yakalamada en yüksek başarıyı vermiştir.
- **F1 Skoru:** Modellerin genel başarısını ölçmek amacıyla incelenen ve kesinlik ile duyarlılığın dengeli bir yansıması olan F1 skorlarında, en yüksek değerin 0,960 ile LSTM modeline ait olduğu görülmektedir. Ardından SVM modeli 0,955 ile gelirken; duyarlılıkları çok düşük kalan Karar Ağacı (%75,5) ve KNN (%60,7) en düşük F1 skorlarına sahip olmuştur.
- **Genel Dağılım:** Grafik genel olarak değerlendirildiğinde, modellerin büyük bir kısmının doğruluk değerlerinin %95 seviyesinin üzerinde olduğu görülmektedir. Ancak LSTM, tehlikeli mesajları kaçırmama (duyarlılık) ile normal mesajları koruma (kesinlik) arasındaki en ideal dengeyi kurmuştur.

Modellerin sayısal performans değerleri ve başarı durumları Tablo 3.1.5'te özetlenmiştir.

Değerlendirme Kriterleri	Doğruluk (Accuracy)	F1-Skoru	Başarı Durumu
LSTM (Derin Öğrenme)	0.989	0.960	En Yüksek Başarı
SVM (C=1.0)	0.988	0.955	Çok Yüksek
Yapay Sinir Ağları (YSA)	0.982	0.931	Yüksek
Random Forest	0.981	0.924	Yüksek
Naive Bayes	0.980	0.920	Yüksek
XGBoost	0.971	0.881	Yüksek
Lojistik Regresyon	0.965	0.851	İyi
Karar Ağaçları	0.945	0.755	Orta
KNN (k=5)	0.925	0.607	Düşük

Tablo 3.1.5 Modellerin Performans Karşılaştırması

3.2 Tartışma

Elde edilen bulgular, model seçiminin SMS spam tespitindeki kritik rolünü doğrulamaktadır. dokuz farklı algoritma arasında özellikle LSTM, en kararlı performansı sergilemiştir. Yapılan

analizler, model seçiminin ve hata türlerinin SMS spam tespitindeki pratik etkilerini ortaya koymaktadır.

3.2.1 En İyi modellerin Başarılarının Karşılaştırılmalı Analizi

Elde edilen sonuçlar incelendiğinde, derin öğrenme mimarisi olan LSTM modelinin karmaşık SMS yapılarını ve kelime ilişkilerini en doğru çözen model olduğu görülmektedir. Geleneksel makine öğrenmesi yöntemleri arasında ise SVM ve Random Forest öne çıkmıştır.

Çalışmada LSTM modelinin %96,0 ile en yüksek F1 skoruna ve %98,9 doğruluk oranına ulaştığı görülmüştür. Bu büyük başarının, modelin metni sadece kelime yığını olarak görmeyip, kelimelerin diziliş sırasını ve bağlamını hafızasında tutmasıyla ilişkili olduğu düşünülmektedir. Klasik bir yöntem olan SVM ise %95,5 F1 skoru ile en başarılı ikinci model olmuştur. SVM, sınıfları ayırmada belirleyici olan destek vektörlerine (kritik mesajlar) odaklanarak doğrusal bir karar sınırı oluşturmuş ve aşırı öğrenmeye düşmeden dengeli sonuçlar üretmiştir.

Random Forest ise tek bir karar ağacı yapısına bağlı kalmak yerine çok sayıda ağacın ortak kararına dayandığı için veri setindeki gürültüye karşı dayanıklı bir yapı sunmuş ve %98,1 doğruluk oranı elde etmiştir.

ROC eğrisi sonuçlarına bakıldığında da LSTM modelinin (0.995) en yüksek AUC değerine sahip olduğu görülmektedir. Hem genel ayırt ediciliği ölçen ROC-AUC değerinde hem de kesinlik-duyarlılık dengesini yansıtan F1-skorunda LSTM en yüksek performanslı model olarak görülmektedir. Bu durum, modelin sadece belirli bir eşik değerinde değil, tüm karar sınırları boyunca en kararlı ve güvenilir sonuçları ürettiğini kanıtlamaktadır.

Genel olarak değerlendirildiğinde, elde edilen bulgular SMS spam tespiti probleminde SVM gibi sınır temelli yöntemlerin ve Random Forest gibi topluluk öğrenme yaklaşımlarının oldukça etkili olduğunu göstermektedir. Ancak kelimelerin anlamsal bağını ve ardışık yapısını kavrayabilen LSTM gibi derin öğrenme modellerinin, metin sınıflandırma problemlerinde kesin çözüm olduğu kanıtlanmıştır.

3.2.2 Hata Türleri ve Algoritma Kısıtlamaları

Sınıflandırma performansları incelendiğinde, KNN ve Karar Ağacı algoritmalarının diğer modellere kıyasla daha düşük başarı gösterdiği dikkat çekmektedir. Özellikle KNN algoritmasının %43,6 gibi düşük bir duyarlılık (recall) değerine sahip olması, literatürde “boyut laneti” olarak ifade edilen durumla ilişkilendirilebilir. TF-IDF vektörleştirme sonrasında oluşan yaklaşık 3.000 öznitelikli veri uzayında, mesafeye dayalı çalışan KNN algoritması, veri noktaları arasındaki uzaklıkları yeterince ayırt edememiştir. Bu durum, modelin spam ve ham mesajları doğru şekilde tespit etmekte zorlanmasına neden olmuştur. Şekil 3.1.3’te yer alan karmaşıklık matrisinde görülen 84 adet “kaçan spam” (false negative) değeri de bu durumu desteklemektedir.

Karar Ağacı modelinin düşük performansı ise, modelin veri içerisindeki karmaşık ve zaman zaman gürültülü yapıya aşırı uyum sağlamasından kaynaklanıyor olabilir. Tek bir ağaç yapısına dayanan bu model, Random Forest gibi topluluk öğrenme yöntemlerinin sağladığı dengeleyici etkiye sahip olmadığından, bazı yanıltıcı kelime örüntülerine fazla duyarlı hale gelmiş ve bu da hatalı sınıflandırmaya yol açmıştır.

Modeller genel olarak değerlendirildiğinde yanlış alarm (false positive) oranlarının düşük seviyede kalması önemli bir avantaj olarak öne çıkmaktadır. Bu durum, sistemin normal kullanıcı mesajlarını spam olarak işaretleme eğiliminin düşük olduğunu göstermektedir.

3.2.3 Karar Mekanizmaları ve Öznitelik Etkisi

Öznitelik önem analizi sonuçları Şekil 3.1.1’de verilmiştir. “Call”, “txt” ve “free” gibi kelimelerin öne çıkması, spam mesajlarda kullanılan tipik dil yapısını göstermektedir. Karar Ağacı modelinin bu kelimeler üzerinden karar vermesi, modelin nasıl çalıştığını daha anlaşılır hale getirmektedir.

Ancak bu modelin duyarlılık (Recall) performansı beklentinin altında kalmıştır. Sadece belirli anahtar kelimelere odaklanmak, bu kelimeleri içermeyen veya daha kapalı bir dille yazılmış mesajları yakalamada yetersiz kalmaktadır.

3.2.4 Araştırma Sorularının Değerlendirilmesi

Giriş bölümünde belirlenen araştırma soruları çerçevesinde elde edilen bulgular şu şekilde analiz edilmiştir:

- **NLP ve TF-IDF Etkisi (Soru 1):** Uygulanan NLP ön işleme adımlarının; metinlerdeki anlamsız kelimeleri ve gürültüyü temizleyerek, sınıflandırma odağını ayırt edici kelimelere taşıdığı görülmektedir. Şekil 3.1.1’de yer alan öznitelik önem analizi incelendiğinde, TF-IDF ağırlıklandırması ile “call”, “free” ve “txt” gibi kelimelerin daha belirgin hale geldiği gözlemlenmektedir. Bu durum, modellerin genel metin yapısından ziyade spam karakteristiğini temsil eden kelimelere odaklanmasını kolaylaştırmıştır. Elde edilen bu bulgular, metin sınıflandırma problemlerinde veri ön işleme adımlarının model performansı üzerindeki belirleyici rolünü desteklemektedir.
- **Model Kıyaslamaları (Soru 2):** Analizlerimizde, kelimeleri geometrik sınırlarla ayıran klasik SVM algoritması güçlü bir performans sergilemiştir. Ancak derin öğrenme mimarisi olan LSTM (0.995 AUC skoru), bu geleneksel modeli açıkça geride bırakmıştır. Bunun temel sebebi, modellerin metni algılama şeklindeki farktır. SVM, SMS’i sadece bir kelime yığını olarak görür ve hangi kelimelerin geçtiğine odaklanır. LSTM ise kelimelerin diziliş sırasını ve cümlelerin bağlamını hafızasında tutar. Sonuç olarak; tehlikeli spam mesajlarını yakalamak için sadece kelimeleri saymak (SVM) yeterli değildir. Metnin anlamını bir bütün olarak kavramak (LSTM), hata payını düşürür.

- **Veri Seti Dengesizliğinin Etkisi (Soru 3):** Çalışmada kullanılan veri setindeki ham mesajların, spam mesajlara oranla sayıca çok daha fazla olması (sınıf dengesizliği), modellerin duyarlılık (recall) başarısında performans kaybına yol açmıştır. Bu durum, doğruluk (accuracy) değerleri yüksek çıksa bile, spam yakalama performansının (recall) düşük kalmasına neden olabilmektedir. Doğruluk oranının yüksek çıkmasının temel sebebi, modellerin sayıca üstün olan ham mesajların büyük bir kısmını doğru tahmin etmesidir. Özellikle KNN gibi mesafe tabanlı algoritmaların, veri setindeki bu dengesizlikten etkilenerek baskın olan "ham mesaj" sınıfına doğru bir eğilim gösterdiği görülmüştür. Bu yönelim sonucunda modelin spam mesajları ayırt etmekte zorlandığı ve 84 adet spam mesajını kaçırarak %43,6 gibi düşük bir duyarlılık seviyesinde kaldığı gözlemlenmiştir. Buna karşılık LSTM modelinin daha dengeli sonuçlar üretmesi, kullanılan ön işleme ve vektörleştirme adımlarının sınıflar arasındaki ayrımı netleştirmede etkili olduğunu göstermektedir.
-

4. SONUÇ VE ÖNERİLER

Bu çalışmada, SMS tabanlı spam mesajların tespiti amacıyla istatistiksel modellerden yapay sinir ağlarına kadar uzanan geniş bir model yelpazesi kapsamlı bir şekilde test edilmiştir. Elde edilen veriler ve deneysel sonuçlar sonunda ulaşılan çıkarımlar şu şekildedir:

4.1. Temel Çıkarımlar

- **Model Performansı:** Yapılan testler sonucunda LSTM algoritması, %98,9 doğruluk ve %96,0 F1-skoru ile en kararlı ve yüksek performanslı model olarak öne çıkmıştır.
- **Vektörleştirme Yaklaşımı:** TF-IDF yönteminin sadece kelime frekansına değil, aynı zamanda kelimenin veri setindeki ayırt ediciliğinin de odaklanması, “call”, “free” ve “txt” gibi spam mesajlara özgü kelimelerin daha belirgin hale gelmesini sağlamıştır. Bu durum, modellerin mesaj içeriğindeki gürültüden arınarak doğrudan spam karakteristiği taşıyan terimlere odaklanmasını sağlamıştır.
- **Sınıf Dengesizliği Etkisi:** Veri setinde normal (ham) mesajların spam mesajlara göre sayıca fazla olması, modellerin özellikle duyarlılık (recall) performansını olumsuz etkilemiştir. Ancak SVM ve LSTM modellerinin bu dengesizliğe rağmen yüksek F1 skorları üretmesi, kullanılan ön işleme adımlarının sınıflar arası ayrımı güçlendirmedeki başarısını kanıtlamaktadır.

4.2. Gelecek Çalışmalar ve Öneriler

Mevcut sistemin başarısını bir adım ileriye taşımak ve daha dinamik bir savunma mekanizması kurmak adına şu adımların atılması planlanmaktadır:

- **Daha Gelişmiş Dil Modellerini Keşfetmek:** Projemizde kelimelerin sırasını ve cümlelerin bağlamını yakalayabilen LSTM modelini başarıyla kullandık ve klasik modellere kıyasla en iyi sonucu aldık. İlerleyen süreçte, doğal dil işlemede çığır açan BERT veya RoBERTa gibi Transformer tabanlı, daha kapsamlı ve büyük ölçekli modellerin de değerlendirilmesi planlanmaktadır.
- **Ön İşleme Geliştirmeleri:** Kelime köklerine inen (stemming/lemmatization) yöntemlerin model performansı üzerindeki etkisi incelenebilir.
- **Gerçek Zamanlı Uygulama:** Geliştirilen modellerin sadece statik bir analiz aracı olarak kalmaması, bir API veya mobil uygulama ile entegre edilerek gerçek zamanlı spam filtreleme sistemi haline getirilmesi mümkündür.
- **Dinamik Veri Güncelleme:** Spam göndericilerinin değişen taktiklerine karşı, sistemin yeni nesil saldırı örnekleriyle düzenli olarak eğitilmesi ve gönderici profili gibi meta verilerin de analize eklenmesi savunma gücünü artıracaktır.

KAYNAKÇA

1. Bayrak, Ö. K., “Makine Öğrenmesi Yöntemleri ile SMS Spam Tespiti,” *Mühendislik Bilimleri ve Tasarım Dergisi*, 11(1), 2023. [Çevrimiçi]. Erişim adresi: <https://dergipark.org.tr/tr/pub/mbtd/issue/75382/1230198>
2. Yılmaz, A., et al., “Metin Madenciliği ve Sınıflandırma Algoritmalarının Performans Analizi,” *Yönetim Bilişim Sistemleri ve Bilişim Teknolojileri Dergisi*, 2024. [Çevrimiçi]. Erişim adresi: <https://dergipark.org.tr/tr/pub/mtuiyb/article/1673236>
3. Gündüz, T., “E-posta ve SMS İletişiminde İstenmeyen İçeriklerin İstatistiksel Yöntemlerle Analizi,” *Akademik Bilişim Konferansı Bildirileri*, Kütahya, 2007. [Çevrimiçi]. Erişim adresi: https://ab.org.tr/ab07/kitap/gunduz_AB07.pdf
4. Almeida, T. A., Hidalgo, J. M. G. ve Yamakami, A., “Contributions to the Study of SMS Spam Filtering: New Collection and Results,” *Proceedings of the 11th ACM Symposium on Document Engineering (DocEng '11)*, ss. 259–262, 2011. [Çevrimiçi]. Erişim adresi: <https://archive.ics.uci.edu/dataset/228/sms+spam+collection>
5. “Makine Öğrenmesi Tabanlı İstenmeyen İçerik Analizi,” TR Dizin, 2023. [Çevrimiçi]. Erişim adresi: <https://search.trdizin.gov.tr/yayin/detay/1109302>
6. Güven, Z. A., “Türkçe E-postalarda Spam Tespiti için Makine Öğrenme Yöntemlerinin ve Dil Modellerinin Analizi,” *Avrupa Bilim ve Teknoloji Dergisi (EJOSAT)*, Özel Sayı 47, ss. 1–6, 2023. [Çevrimiçi]. Erişim adresi: <https://dergipark.org.tr/tr/pub/ejosat/article/1234079>
7. “İstenmeyen Elektronik Posta (Spam) Tespitinde Karar Ağaçları Algoritmalarının Performans Kıyaslaması,” *Academia.edu*, 2015. [Çevrimiçi]. Erişim adresi: <https://www.academia.edu/12236589>
8. Saputra, N. J., “Analysis of SMS Spam Detection Using TF-IDF: A Study on SMS Spam Collection Dataset,” *Jurnal Sosial dan Teknologi (SOSTECH)*, 4(4), ss. 213–217, 2024.
9. Johari, M. F. ve ark., “Key Insights into Recommended SMS Spam Detection Datasets,” *Scientific Reports*, 15(8162), 2025. [Çevrimiçi]. Erişim adresi: <https://doi.org/10.1038/s41598-025-92223-1>
10. Scikit-learn Developers, “Supervised Learning,” *scikit-learn 1.4 Documentation*, 2024. [Çevrimiçi]. Erişim adresi: https://scikit-learn.org/stable/supervised_learning.html
11. GeeksforGeeks, “Machine Learning Algorithms,” *GeeksforGeeks*, 2024. [Çevrimiçi]. Erişim adresi: <https://www.geeksforgeeks.org/machine-learning-algorithms/>